

Pose-Tag 멀티모달 융합 기반 K-pop 안무 유사 구간 검출 관한 연구

김정인, 김수만, 배문경, 백경지, 윤수연*

kji030606@gmail.com, suman2022@naver.com, mung47211@gmail.com, samsak@kookmin.ac.kr,
*1104py@kookmin.ac.kr

A Study Of K-pop Choreography Similarity Detection Based on Pose-Tag Multimodal Fusion

Kim Jeong In, Kim Suman, Bae Moon Gyeong, Baek Gyeong Ji, Yoon Soo Yeoun*
Kookmin Univ.

본 연구는 K-pop 영상 간 안무 유사도 비교를 위해 ST-GCN 기반 pose feature 와 HRNet 좌표 기반 pair-level Tag 를 결합한 멀티모달 유사도 모델을 제안한다. 기존 pose-only 방법은 두 영상 간 세부 동작 차이를 명시적으로 반영하는 데 한계가 있어, YOLO 와 HRNet 으로 추출한 2D pose 기반 MotionBERT 임베딩을 pose feature 로 변환하고, HRNet 좌표에서 산출한 Tag feature 를 결합하였다. 제안 모델은 검증 피어슨 상관계수 0.9766 을 달성하여 단일 모달 모델(0.8653) 대비 약 11%p 향상되었으며, 추론 단계에서 부분적으로 동일한 안무를 포함하는 테스트 영상 쌍에 대해 동일 구간 3 개를 정확히 탐지하여 실제 안무 비교 과제에서의 적용 가능성을 확인하였다.

I. 서론

K-pop 안무의 유사성 판단은 전문가의 주관적 평가에 의존하고 있어 정량적 기준이 부재한 실정이다. 본 연구에서는 두 안무 영상을 입력받아 유사 구간을 자동 탐지하고 신체 부위별 유사도를 수치화하는 시스템을 제안한다. 본 연구에서는 3D pose representation 을 기반으로 한 feature 와 Tag 기반 의미 정보를 결합한 Pose+Tag 구조인 멀티모달을 통해 검증 상관 계수 0.9766 을 달성하였다.

II. 관련연구

스켈레톤 기반 동작 유사도 비교에서 DTW(Dynamic Time Warping)는 두 시퀀스 간 시간적 정렬을 수행하여 프레임 단위 거리를 산출하는 대표적 방법이나[4], 원시 좌표를 직접 비교하므로 체형 차이, 촬영 시점, 동작 속도 변화에 민감하며 $O(N \times M)$ 복잡도로 실시간 적용이 어렵다. ST-GCN 은 인체 관절을 그래프 구조로 표현하고 관절 간 공간적 관계와 시간적 변화를 함께 학습하여 이러한 한계를 보완할 수 있으나[1], 대규모 동작 라벨 데이터를 요구하며, 동일 안무를 다수의 커버 영상으로 구성된 학습 데이터가 부재한 K-pop 도메인에서는 표현력 학습에 한계가 있다.

HRNet 은 고해상도 표현을 유지하면서 인체 관절 좌표를 정밀하게 추정하는 네트워크로[3], 본 연구에서는 YOLOv8m 으로 인물 영역을 검출한 후 HRNet-W48 로 17 개 관절 좌표를 추출하여 포즈 임베딩 생성과 Tag feature 추출의 기반으로 사용하였다. MotionBERT 는 Transformer 기반의 포즈 시퀀스 표현 모델로[2], 대규모 모션 데이터에서 사전학습된 인코더를 활용하여 K-pop 도메인의 데이터 부족 문제를 우회할 수 있다.

본 연구에서는 DTW 를 유사도 판별에 직접 사용하는 대신 학습 라벨 생성 용도로만 활용하고, 실제 유사도 예측은 ST-GCN 기반 Pose feature 와 HRNet 좌표 기반 Pair-level Tag feature 를 결합한 딥러닝 모델이 수행하도록 설계하였다. 이를 통해 DTW 의 시퀀스 매칭 능력을 딥러닝 모델에 전이하면서도 체형 및 시점 변화에 강건하고, 관절의 시공간적 움직임과 두 영상 간 의미적 동작 차이를 함께 반영하는 안무 유사도 측정 구조를 구현하였다.

III. 실험 설계

3.1 데이터 셋 구성

구분	항목	값 (개)
데이터 셋	총 곡 수	157
	총 댄스 영상	471
페어 구성	총 샘플링 페어 수	1884
	Positive Pair	동일 곡 영상 쌍
	Negative Pair	Hard/Mid/Easy (DTW 기반 분리)

유사도 라벨링은 Soft-DTW ($\gamma=0.1$)를 사용하여 모든 영상 pair 간 유사도를 산출하고, 이를 [0, 1] 범위로 정규화하여 학습 target 으로 사용하였다. 학습과 검증 데이터의 분할은 곡 단위로 수행하여, 동일 곡에 속하는 영상이 학습과 검증에 동시에 포함되지 않도록 데이터 누수를 방지하였으며, 학습에 1,515 쌍, 검증에 169 쌍을 사용하였다.

3.2 데이터 전처리와 유사도 모델 설계

입력 영상의 각 프레임에서 YOLOv8m 을 이용하여 인물 바운딩 박스를 검출하고, 검출된 인물 영역에 HRNet-W48 을 적용하여 17 개 관절 좌표를 추출한다. 추출된 관절 좌표는 x 좌표, y 좌표, confidence score 로 구성되며, 이후 torso normalization 을 수행하여 영상 간 신체 크기 및 위치 차이에 따른 영향을 완화한다.

정규화된 2D pose 를 기반으로 MotionBERT+LoRA 임베딩 [F, 17, 512]를 생성하고, 이를 ST-GCN 기반 pose encoder 의 입력으로 사용한다. Pose encoder 에서는 먼저 Hip Centering 을 적용하여 관절 표현을 hip 기준의 상대 표현으로 변환한 뒤, ST-GCN Block 을 통해 관절 간 공간적 관계와 프레임 간 시간적 움직임을 학습한다. 이후 attention 기반 temporal pooling 을 거쳐 영상당 640 차원의 Pose embedding 을 얻는다.

Tag branch 에서는 MotionBERT 나 ST-GCN 의 중간 feature 를 사용하지 않고, HRNet 에서 추출한 2D pose coordinate 만을 기반으로 두 영상 쌍의 동작 차이를 rule-based 방식으로 비교한다. 이를 통해 6 개의 score statistics(평균 · 표준편차 등)와 28 개의 tag vocabulary(신체 부위별 각도 · 거리 차이)로 구성된 34 차원의 Pair-level Tag Feature 를 생성한다. 즉, Tag feature 는 개별 영상 단위가 아니라 두 영상의 관계를

나타내는 쌍별 보조 특징이다.

최종 모델은 Pose feature 와 Pair-level Tag Feature 를 결합한 Pose+Tag Siamese 구조로 설계하였다. 두 영상의 Pose embedding 으로부터 차이 정보와 공통 정보를 추출한 뒤 Pair-level Tag Feature 와 결합하고, MLP classifier 와 sigmoid 를 거쳐 [0, 1] 범위의 안무 유사도 점수를 출력한다. 이를 통해 제안 모델은 두 안무의 동일 여부뿐 아니라 어느 정도 유사한지를 연속적인 수치로 예측할 수 있다.

추론 단계에서는 5 초 단위 Coarse 매칭으로 유사 후보 구간을 탐지한 후, 후보 구간 주변을 1 초 단위 Sliding Window 로 재탐색하여 세부 유사 구간을 확인한다. 이를 통해 전체 영상 수준의 유사도와 시간 구간별 부분 유사도를 함께 분석한다.

IV. 모델 성능 평가 분석

아래는 각 실험 단계별 성능을 비교한 것이다. MediaPipe 의 포즈 추출 정확도 한계를 HRNet-W48 로 보완하여 0.9272 를 달성하였고, HRNet 기반 수작업 feature 를 추가한 경우 0.9570 으로 성능이 향상되었다. 최종적으로 HRNet 좌표 기반 pair-level tag feature 를 결합한 제안 모델은 0.9766 의 가장 높은 검증 상관계수를 달성하였다.

순서	모델	Val_Corr
1	Mediapipe + BERT + GCN	0.8653
2	pose-only (ST-GCN 기반 pose feature)	0.9272
3	pose + HRNet feature	0.9570
4*	pose + HRNet 기반 pair-level tag feature (제안)	0.9766

제안 모델은 이전 실험 모델과 달리 Pred vs Target 그래프에서 모델의 예측값이 정답 유사도에 가깝게 분포한다.(Fig2) 이는 모델이 두 안무의 동일 여부만을 판단하는 것이 아니라 어느 정도 유사한지를 정량적으로 산출할 수 있음을 의미한다.

4.1 추론 결과 분석

부분적으로 동일한 안무를 포함하는 테스트 영상 쌍에 대해 Coarse-to-Fine 매칭을 통해 0~5 초, 5~10 초, 10~15 초의 동일 안무 구간 3 개를 탐지하였다. <Fig.1>는 5 초 단위 Cross-Similarity heatmap 으로, 대각선 영역에서 높은 유사도가 관측되어 시간 정렬이 정확히 수행되었음을 확인할 수 있다. 이를 통해 사용자는 어떤 구간이 유사한지뿐만 아니라, 각 구간이 얼마나 유사한지를 정량적으로 확인할 수 있다.

탐지된 구간에 대해 신체 부위별 유사도까지 함께 제시하였다. 즉, 제안 시스템은 기존의 동일/상이 판단 중심의 방식에서 나아가, 시간 구간별 · 신체 부위별 수치 기반 분석<Fig.2>을 제공한다는 점에서 실질적인 안무 피드백 도구로 활용될 수 있다.

V. 결론

본 연구를 통해 Pose-only 방식의 한계를 발견하였다. 관절 추출 결과 만으로는 순간의 신체 부위 간의 유사성 파악만 가능하며, 안무의 문맥을 파악하지 못하는 한계가 있었다. 이를 해결하기 위해 HRnet 관절 추출 결과와 pair-level-tag 를 도입하여 ST-GCN 기반으로 두 영상에서 문맥과 관계를 비교하는 멀티모달 구조를 설계한

결과, 기존 Pose-only DTW 비교 결과보다 높은 추론 정확도를 보인다.

모델은 두 영상의 유사 여부와 함께, 정답 유사도가 가까운 연속적인 수치 값을 표현할 수 있다. 또한, 시간 구간별 유사도와 신체 부위별 수치화 된 유사도 지표를 함께 제공함으로써 기존의 전문가 주관 비정형적 평가에 의존하던 안무 유사성 판단에 수치적인 정량적 근거를 제공하고자 하였다. 이는 안무 저작권 분쟁 시 전문가마다의 편차를 상쇄하고 하나의 기준점이 되는 객관적 지표로서 자리 잡을 수 있다. 이에 나아가 본 연구는 안무 유사도 측정을 연속적 수치 기반의 해석 가능한 분석 도구로 발전시키는데 기여하고자 한다.

ACKNOWLEDGMENT


본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW 중심대학사업의 연구결과로 수행되었음. (2022-0-00964)

This research was supported by the Ministry of Science and ICT (MSIT) and the Institute for Information & Communications Technology Planning & Evaluation (IITP) under the National Program of Excellence in Software (2022-0-00964).


참 고 문 헌

- [1] S. Yan et al., "Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition," AAAI, 2018.
- [2] W. Zhu et al., "MotionBERT: A Unified Perspective on Learning Human Motion Representations," ICCV, 2023.
- [3] J. Wang et al., "Deep High-Resolution Representation Learning for Visual Recognition," TPAMI, 2020.
- [4] H. Sakoe and S. Chiba, "Dynamic Programming Algorithm Optimization for Spoken Word Recognition," IEEE TASSP, 1978.

Appendix



<Fig.1>



<Fig.2>