

한국어 뉴스의 의미적 중복 제거를 위한 STS-NLI 결합 기반 신규 정보 탐지

김수만, 윤수연*

국민대학교

tnaks123@kookmin.ac.kr , *1104py@kookmin.ac.kr

Novel Information Detection Using an STS-NLI Combined Approach for Semantic Deduplication in Korean News

Suman-Kim, Soo-Yeon Yoon*

Kookmin Univ

요 약

문장 임베딩 기반 코사인 유사도는 텍스트의 전체적 유사도를 효과적으로 측정하지만, 부분적으로 새로운 정보가 포함된 텍스트를 식별하는 데 한계를 가진다. 본 연구는 의미적 텍스트 유사도(STS)로 유사 기사 쌍을 필터링하고, 자연어 추론(NLI)의 중립(neutral) 판정을 신규 정보의 대리 지표로 활용하는 2 단계 결합 파이프라인을 제안한다. KorSTS 벤치마크에서 한국어 STS 모델들의 성능과 한계를 실증하고, KorNLI로 파인튜닝한 NLI 분류기의 신규 정보 탐지 가능성을 검증한다. 본 연구는 한국어 텍스트에서 STS와 NLI의 결합 적용에 대한 실증적 분석을 제공하고, 정보적 신규성을 보존하는 의미적 중복 제거를 위한 실용적 프레임워크를 제시한다.

1. 서론

디지털 뉴스 환경에서 동일 사건에 대한 기사가 반복 생산되며, 정보 소비자는 중복 속에서 새로운 정보를 식별해야 한다. 표준적 접근인 코사인 유사도는 두 텍스트의 의미적 일치도를 단일 스칼라로 압축하므로, 부분적 신규성이 존재하는 텍스트 쌍에서 한계를 가진다. 실제로 필자의 반도체 뉴스 수집 사례에서, 새로운 정보를 포함한 기사가 코사인 유사도 0.85~0.92로 "중복" 판정되어 나머지 8%~15%의 핵심 정보가 소실되는 문제를 경험하였다.

본 연구는 STS로 유사 기사 쌍을 필터링하고, NLI의 Neutral 판정으로 문장별 신규 정보를 탐지하는 2 단계 파이프라인을 제안한다. 카카오프레인의 KorNLI 데이터셋 및 자체 수집한 한국어 뉴스 데이터를 활용하여 그 가능성을 검증한다.

2. 관련 연구

2.1 STS 기반 의미 유사도 측정

STS는 문장 임베딩 벡터 간 코사인 유사도 $\cos(A, B) = (A \cdot B) / (|A| \times |B|)$ 로 의미적 가까움을 측정하며, 대칭적·연속적 특성을 가진다. 본 연구에서는 paraphrase-multilingual-MiniLM-L12-v2, ko-sroberta-multitask, ko-sbert-sts 세 SBERT 모델을 비교한다.

2.2 코사인 유사도의 한계와 NLI 활용 가능성

코사인 유사도는 두 텍스트의 비교를 단일 스칼라로 압축하므로, 정보의 방향성이 없고 "어디가 같고 어디가 다른지"를 알 수 없다는 근본적 한계를 가진다. 자연어 추론(NLI)은 전제와 가설 간의 관계를 Entailment, Contradiction, Neutral로 분류하는 태스크로, STS와 달리 비대칭적이며 범주적인 특성을 가진다. Ghosal et al. (2022)은 텍스트 함의가 비신규 정보 탐지에 가깝다고 보고하였으며, Laban et al. (2022)은 문장 단위 NLI 적용으로 문서 수준 불일치를 탐지할 수 있음을 보였다. [2] [3]

NLI는 cross-encoding으로 [CLS] P [SEP] H [SEP] 형태의 입력을 Transformer에 통과시켜, bi-encoding에서 불가능한 세밀한 의미 비교를 가능하게 한다. 본 연구는 Neutral 판정을 신규 정보의 대리 지표로 활용하여, STS의 한계를 보완하는 접근을 취한다.

3. 실험 설계

3.1. 데이터 수집 및 전처리

실험 데이터는 네이버 뉴스 API 및 크롤링을 통해 수집된 반도체 관련 한국어 뉴스 1,184 개이며, 각 기사의 제목과 본문 최대 500자를 결합하여 임베딩 입력으로 사용하였다. 뉴스가 순차적으로 유입되는 실시간 환경을 시뮬레이션하여 각 기사와 기존 축적된 기사 간의 최대 코사인 유사도를 산출하였다.

STS 모델은 다국어 경량 모델(paraphrase-multilingual-MiniLM-L12-v2), 한국어 멀티태스크 모델(ko-sroberta-multitask), 한국어 STS 특화 모델(ko-sbert-sts)의 세 가지를 비교한다.

NLI 모델은 KLUE-RoBERTa-base 위에 3-class 분류 헤드를 얹고, KorNLI(SNLI + MNLI, 총 942,854 쌍)로 파인튜닝하여 구축하였다. 검증 및 테스트에는 XNLI dev/test 세트(각 5,010 쌍)를 사용하였으며, 학습률 $2e-5$, 배치 256, 에폭 3, NVIDIA A100 환경에서 Best Epoch 전략을 적용하였다.

3.2 STS-NLI 결합 파이프라인

파이프라인은 2 단계로 구성된다. 1 단계에서 ko-sbert-sts로 코사인 유사도 0.5 이상인 후보 쌍을 선정하고, 2 단계에서 기사 원문을 문장 단위로 분절한 뒤 파인튜닝된 NLI 모델을 적용한다. 기존 기사의 각 문장을 전제(premise)로, 새 기사의 각 문장을 가설(hypothesis)로 놓아 NLI 판정을 수행한다.

3.3 신규 정보 판정 기준

새 기사의 각 문장에 대해, 기존 기사 전체 문장과 Entailment 확률 최댓값이 0.5 미만이면 해당 문장을 신규 정보로 판정한다. 즉, 기존 기사의 어떤 문장으로부터도 함의되지 않는 문장은 새로운 정보를 담고 있는 것으로 간주한다. 각 뉴스 쌍에 대해 신규 정보 비율(Novelty Ratio = 신규 문장 수 / 전체 문장 수)을 산출하였다. 성능 평가를 위해 ko-sbert-sts 코사인 유사도 구간별 등화 추출(stratified sampling)로 총 100 개 쌍을 선정하였다(0.5~0.7: 20 개, 0.7~0.8: 25 개, 0.8~0.9: 30 개, 0.9~1.0: 25 개).

4. 실험 결과 및 성능평가

4.1 STS 모델별 유사도 분포 분석

세 모델 모두 0.7 이상 구간에 86~89%가 집중되며, 이는 뉴스 도메인의 높은 의미적 중복률을 반영한다. 모델 간에는 paraphrase-multilingual 이 0.7~0.9 구간에 27.0%를 배치하여 분별력이 가장 높았고, ko-sroberta-multitask 는 0.9 이상 비율이 71.6%로 유사도를 가장 높게 평가하는 경향을 보였다.

[표 1 STS 모델 별 성능비교]

Cosine Range	Model-1	Model-2	Model-3
0.0 ~ 0.5	5 (0.4%)	9 (0.8%)	9 (0.8%)
0.5 ~ 0.7	120 (10.1%)	122 (10.3%)	149 (12.6%)
0.7 ~ 0.9	320 (27.0%)	205 (17.3%)	255 (21.5%)
0.9 ~ 1.0	739 (62.4%)	848 (71.6%)	770 (65.1%)

4.2 NLI 모델 성능 평가

[표 2 NLI 모델 파인튜닝 결과-1]

Epoch	Train Loss	Train Acc	Dev Loss	Dev Acc
1	0.5506	76.87%	0.4715	81.41%
2	0.3989	84.77%	0.4369	83.25%
3	0.3432	87.12%	0.4578	82.57%

Best Epoch 2 의 모델로 Test Accuracy 83.3%를 달성하였으며, 이는 원 논문의 KLUE-RoBERTa-large(83.67%)와 거의 동등한 수치이다.

[표 3 NLI 모델 파인튜닝 결과-2]

Epoch	Pred Entailment	Pred Neutral	Pred Contradiction	sum
True Entailment	1,369	224	77	1670
True Neutral	165	1,352	153	1670
True Contradiction	48	172	1,450	1670

클래스별 정확도는 Contradiction 86.8%, Entailment 82.0%, Neutral 81.0% 순으로, Neutral 의 호호성으로 인해 가장 낮은 정확도를 보였다. Neutral→Entailment 오분류율은 9.9%로, 실제 신규 정보의 약 90%를 정확히 탐지할 수 있는 수준이며, Neutral 판정이 신규 정보 탐지의 프록시로 충분히 기능할 수 있음을 시사한다.

4.3 유사도 구간별 신규 정보 탐지 결과

코사인 유사도와 신규 정보 비율은 명확한 역의 상관관계를 보이며, NLI 판정의 타당성을 뒷받침한다. 핵심적 발견은 0.8~0.9 구간에서 도출된다. 해당 구간의 평균 코사인

유사도는 0.849 로 임계값 기반 필터링에서 "중복"으로 판정될 영역이나, NLI 분석 결과 평균 26.9%의 문장이 신규 정보로 식별되었다. 이는 서론에서 제기한 "80% 동일하지만 20%의 새로운 정보를 포함하는 기사"의 문제가 실재함을 정량적으로 실증한다. 반면 0.9~1.0 구간에서는 신규 정보 비율이 3.1%에 불과하여, 해당 구간을 완전 중복으로 판정하는 것이 합리적임을 시사한다.

[표 4 유사도 구간 신규 정보 탐지 비율]

구간	샘플 수	평균 코사인 유사도	평균 신규 정보 비율
0.5 ~ 0.7	20 쌍	0.614	44.5%
0.7 ~ 0.8	25 쌍	0.746	39.1%
0.8 ~ 0.9	30 쌍	0.849	26.9%
0.9 ~ 1.0	25 쌍	0.985	3.1%

5. 결론

이상의 결과는 STS-NLI 결합 파이프라인의 유효성을 보여준다. STS 의 코사인 유사도는 0.9 이상 구간에서 높은 신뢰도의 중복 판정을 제공하며, NLI 는 0.8~0.9 구간에서 26.9%의 신규 정보를 문장 단위로 식별하여 코사인 유사도의 한계를 보완한다.

제안된 파이프라인은 뉴스 포털의 중복 필터링 시스템에서 신규 정보를 하이라이트하거나, 사건 타임라인을 자동 구성하는 전처리 단계로 활용될 수 있다.

5.1 한계점 및 추후 방향

본 연구는 KorNLI 가 영어 번역 기반이므로 한국어 고유의 언어 현상에 대한 성능이 제한적이며, cross-encoding 특성상 STS 임계값 설정이 효율성과 정확성의 트레이드오프를 결정한다는 한계를 가진다. 향후에는 한국어 뉴스 코퍼스 기반 NLI 데이터셋을 자체 구축하여 도메인 적합성을 높일 필요가 있다.

Acknowledgement

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW 중심 대학사업의 연구결과로 수행되었음. (2022-0-00964)

This research was supported by the Ministry of Science and ICT (MSIT) and the Institute for Information & Communications Technology Planning & Evaluation (IITP) under the National Program of Excellence in Software (2022-0-00964).

참고문헌

- [1] Ham, J., Choe, Y. J., Park, K., Choi, I., & Soh, H. (2020). "KorNLI and KorSTS: New Benchmark Datasets for Korean Natural Language Understanding." *Findings of EMNLP 2020*, pp. 422-430.
- [2] Ghosal, T. et al. (2022). "Novelty Detection: A Perspective from Natural Language Processing." *Computational Linguistics*, 48(1), pp. 77-117.
- [3] Laban, P. et al. (2022). "SummaC: Re-Visiting NLI-based Models for Inconsistency Detection in Summarization." *TACL*, 10, pp. 163-177.

Appendix

본 연구의 학습 코드, 추론 코드, 파인튜닝 모델 가중치 및 실험 데이터셋은 아래 저장소에서 공개한다.

<https://github.com/nomad0884/Beyond-Cosine-Similarity>